BIOSTATISTIKA

L11

Vylézají z tůní, které vyschly, menší žabky?



Hierarchická data a náhodné efekty

cuni-natur-biostatistics.github.io/materialy.html

Ilustrace vytvořená pomocí AI.

Jak velké žabky vylezou z tůně, která vyschla?



Ilustrace vytvořená pomocí AI.

V suchých letech mnoho tůní **vyschne** a po deštích se naplní. Pulci v nich dorůstají v žabky a velikost žabky rozhoduje o tom, jak dobře přežije první měsíce na souši.

Budou žabky z tůně, která vyschla, oproti tůni, která nevyschla...

A
menší

B
stejně velké

C
větší

Co si pamatujete z minulé lekce?

Odpovězte samostatně na tři krátké otázky. Společné odpovědi projdeme po hlasování.

Kterým výpočtem zjistíte podle modelu Mocninný vztah, kolikrát víc druhů má ostrov stokrát větší?

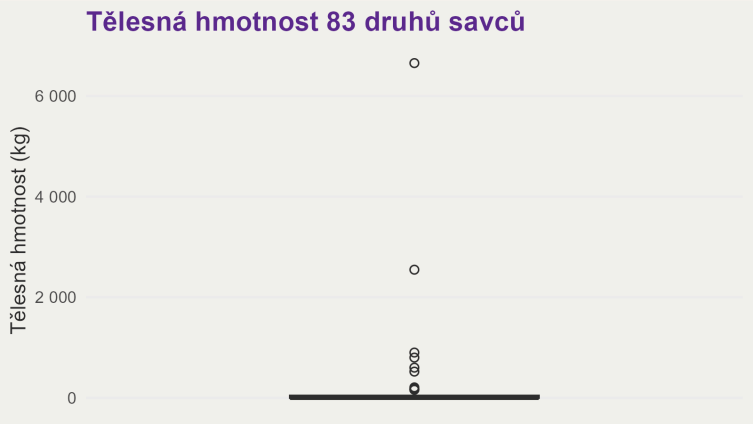
Koeficienty modelu Mocninný vztah
log(pocet_druhu) ~ log(plocha_km2) · 30 ostrovů Galapág

Člen	Odhad	95% interval
intercept	2,904	2,58 až 3,23
log(plocha)	0,389	0,30 až 0,47

- 0,389 × 100 (sklon vynásobený stem)
- 0,389 × log(100) (sklon vynásobený logaritmem stovky)
- 100 na 0,389 (sto umocněné na sklon)
- 2,904 + 0,389 × 100 (intercept plus sklon krát sto)

SPRÁVNÁ ODPOVĚĎ
: 100 na 0,389 (sto umocněné na sklon)
Na logaritmických osách je sklon exponent: násobek plochy umocníme na sklon. 100 na 0,389 je asi 6,0, totéž jako 10 na 0,389 dvakrát za sebou (2,45 × 2,45). Součin 0,389 × log(100) je jen změna na logaritmické ose, kterou je ještě potřeba převést zpět.

Krabicový graf hmotností v kilogramech označil 11 z 83 druhů savců jako možná odlehlé. Kolik druhů označí krabicový graf stejných hmotností převedených na z-skóre?



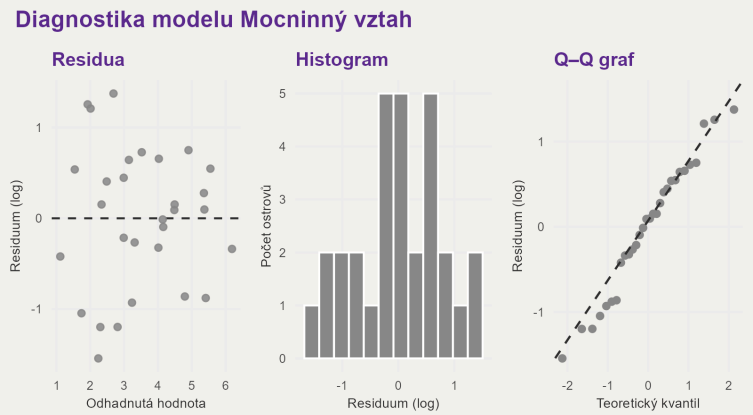
- Žádný: z-skóre zkrátí dlouhý chvost podobně jako logaritmus.
- Stejně 11: z-skóre mění jen polohu a měřítko, ne tvar.
- Méně než 11: z-skóre zmenší rozptyl hmotností na jedničku.
- Nelze určit: z-skóre už nemá žádné jednotky hmotnosti.

SPRÁVNÁ ODPOVĚĎ

: Stejně 11: z-skóre mění jen polohu a měřítko, ne tvar.

Z-skóre od každé hmotnosti odečte průměr a vydělí ji směrodatnou odchylkou. Posune a zmenší osu, ale tvar rozdělení zůstane, a s ním i dlouhý chvost a stejní odlehlí savci. Tvar mění až transformace jako logaritmus.

Grafy residuí modelu Mocninný vztah neukazují žádný zřetelný problém. Co z nich přesto poznat nemůžeme?



Zda jsou ostrovy jednoho souostroví navzájem nezávislá pozorování.

Zda je vztah na logaritmických osách přibližně přímý, nebo zakřivený.

Zda mají residua přibližně souměrné rozdělení bez dlouhého chvostu.

Zda je rozptyl residuí podobný u malých i u velkých ostrovů.

SPRÁVNÁ ODPOVĚĎ

: Zda jsou ostrovy jednoho souostroví navzájem nezávislá pozorování.
Graf residuí ukáže oblouk, vějíř i dlouhý chvost. Neukáže ale, zda si některé ostrovy nejsou podobné jen proto, že jsou sousedé a vyměňují si semena a živočichy. Nezávislost posuzujeme podle toho, jak data vznikla.

Výsledky učení

Po lekci dokážete:

- pojmenovat hierarchii v datech (opakovaná měření, lokality, bloky) a určit, na které úrovni se mění zkoumaný prediktor;
- určit jednotku nezávislé replikace a vysvětlit, jak pseudoreplikace zkresluje standardní chybu, intervaly spolehlivosti a p-hodnoty;
- rozhodnout, zda má být skupinová proměnná pevným, nebo náhodným faktorem, a zdůvodnit to biologickou otázkou;
- odhadnout lineární model s náhodným interceptem, interpretovat jeho výsledek a porovnat variabilitu mezi skupinami a uvnitř skupin;
- popsat, kdy je potřeba smíšený model místo jednoduchého `lm()` a kdy stačí jednodušší řešení.

Žabky z pokusných nádrží

Pokus se 16 nádržemi



- Kansas 2021: 64 nádrží po 1 000 litrech jako umělé tůně.
- Polovina **vyschla** a byla doplněna vodou.
- V každé 50 pulců skokana *Lithobates blairi*.
- Žabky vylezly z 16 nádrží bez ryb.

Ilustrace vytvořená pomocí AI.

Data: Ward et al. (2023), *Freshwater Biology*; Dryad, CC0

Které nádrže vyschly a kolik žabek z nich vylezlo?

nevyschla	N9	N14	N27	N34	N40	N45	N51	N54
	38	40	16	12	40	11	15	18
vyschla a byla doplněna vodou	N2	N4	N5	N15	N21	N22	N52	N53
	19	43	44	43	19	47	41	39

Rozhodovalo se o vyschnutí u každé žabky zvlášť, nebo u celé nádrže?

Vždy u celé nádrže.

Vyschlé: 295 žabek, nevyschlé: 190, přitom všude 50 pulců.

Jeden řádek tabulky představuje jednu žabku

```r
# Jeden řádek = jedna žabka
data_zabky <-
  read.csv(
    file = here::here("data", "zabky_nadrze.csv")
  )

# Nevyschlé nádrže budou referenční skupinou
data_zabky$vyschnuti <-
  factor(
    x = data_zabky$vyschnuti,
    levels = c("nevyschla", "vyschla")
  )
# Nádrže v pořadí z tabulky (podle čísla)
data_zabky$nadrz <-
  factor(
    x = data_zabky$nadrz,
    levels = unique(data_zabky$nadrz)
  )
str(object = data_zabky)

colSums(x = is.na(x = data_zabky))
```

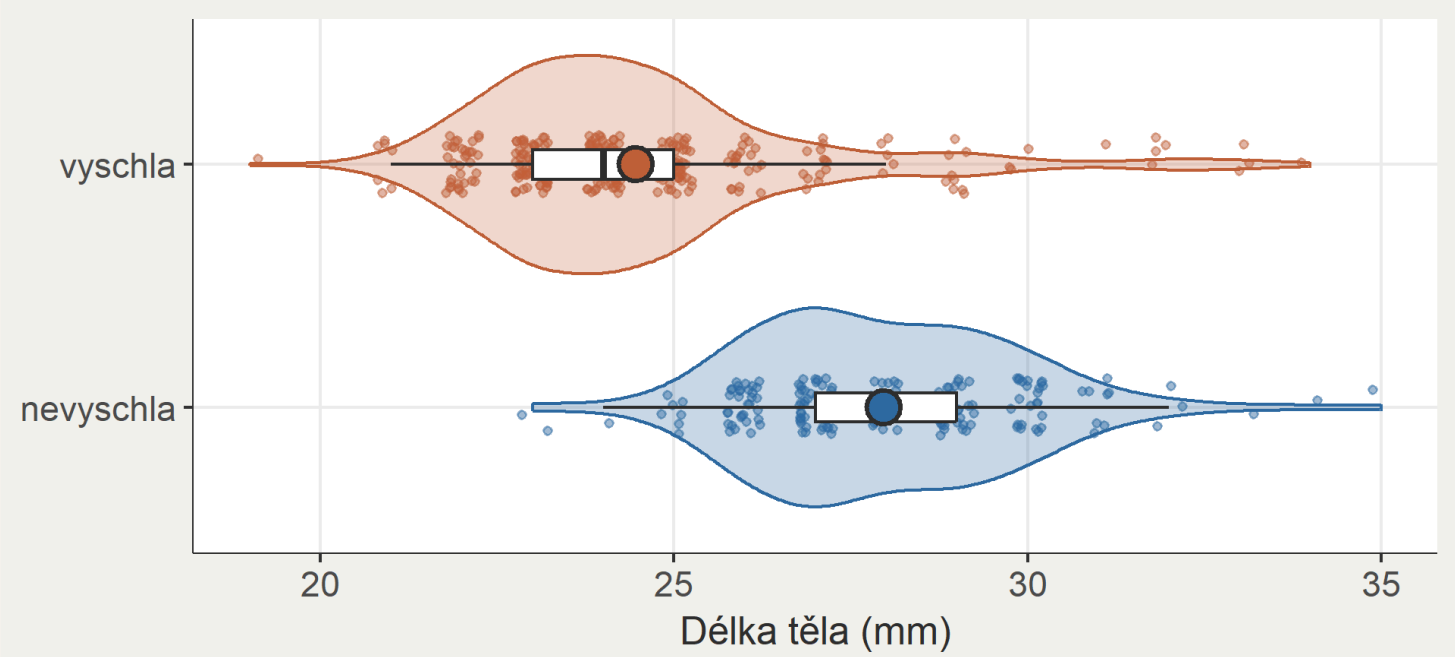
Který sloupec říká, ze které nádrže žabka vylezla?

```
'data.frame':   485 obs. of  8 variables:
 $ nadrz             : Factor w/ 16 levels
 $ vyschnuti         : Factor w/ 2 levels
 $ poradi_zabky      : int  1 2 3 4 5 ...
 $ datum_metamorfozy: chr  "2021-06-30" "
 $ den_pokusu        : int  53 53 53 53 56
 $ delka_tela_mm     : int  25 23 26 24 25
 $ hmotnost_mokra_g : num  0.9 0.9 1.2 0.
 $ hmotnost_sucha_g : num  0.137 0.133 0.


             nadrz          vyschnuti
                 0                  0
       den_pokusu      delka_tela_mm  hmot
                 0                  0
```

Sloupec `nadrz` · 0 chybějících hodnot · délka 19–35 mm

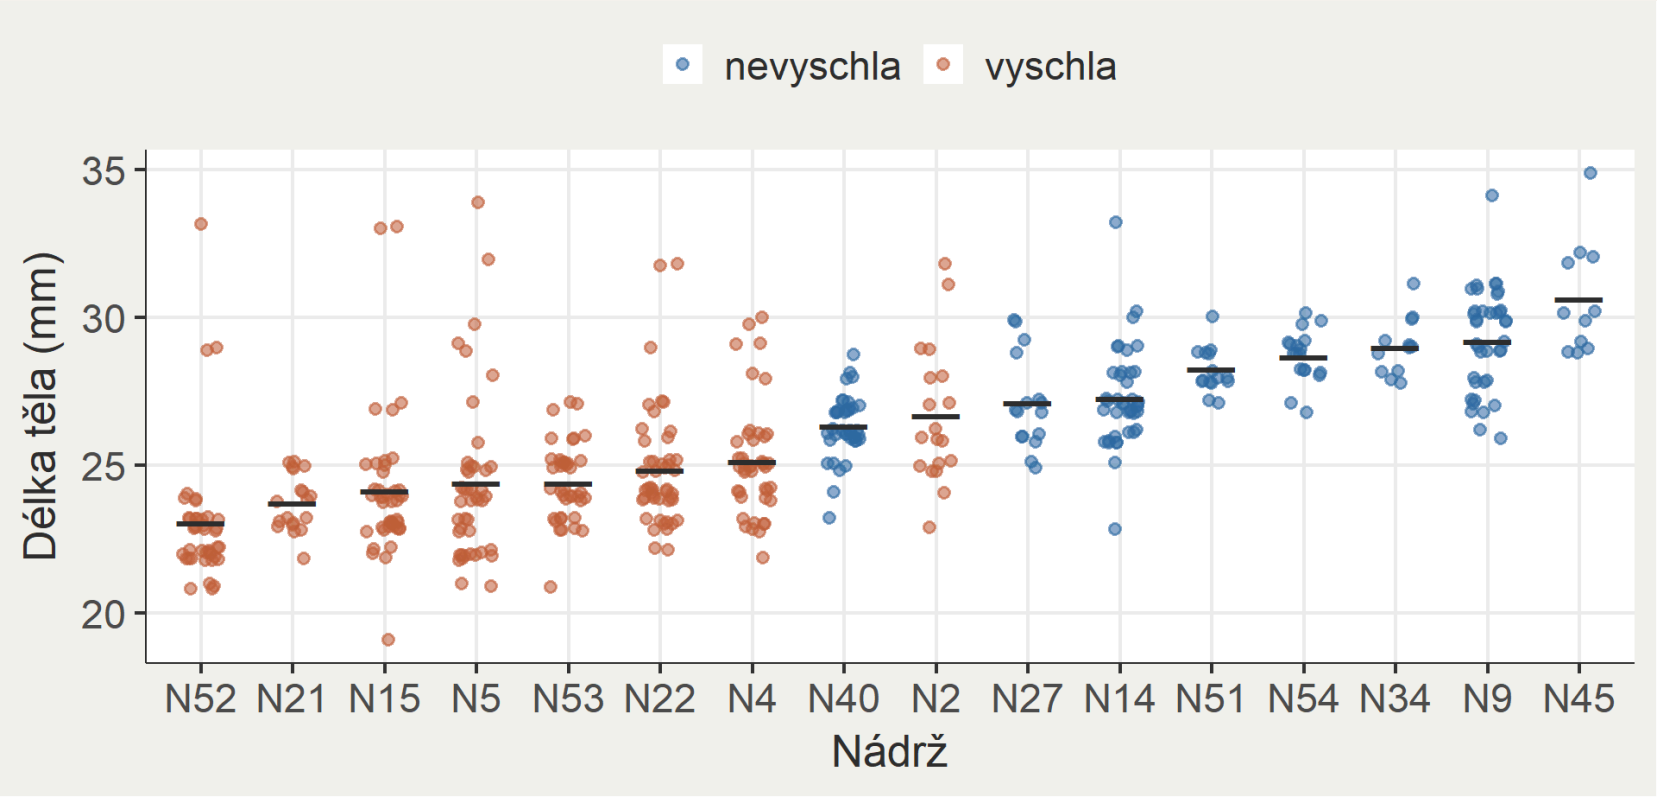
Jak velké jsou žabky z vyschlých a nevyschlých nádrží?



Ve dvojici: Jak velký je rozdíl? Překrývají se obě skupiny?

Průměr: nevyschlé 28,0 mm, vyschlé 24,5 mm. Rozdíl kolem 3,5 mm vypadá jako jasný výsledek. Jak jste hlasovali na začátku?

Stejné žabky rozdělené podle nádrží

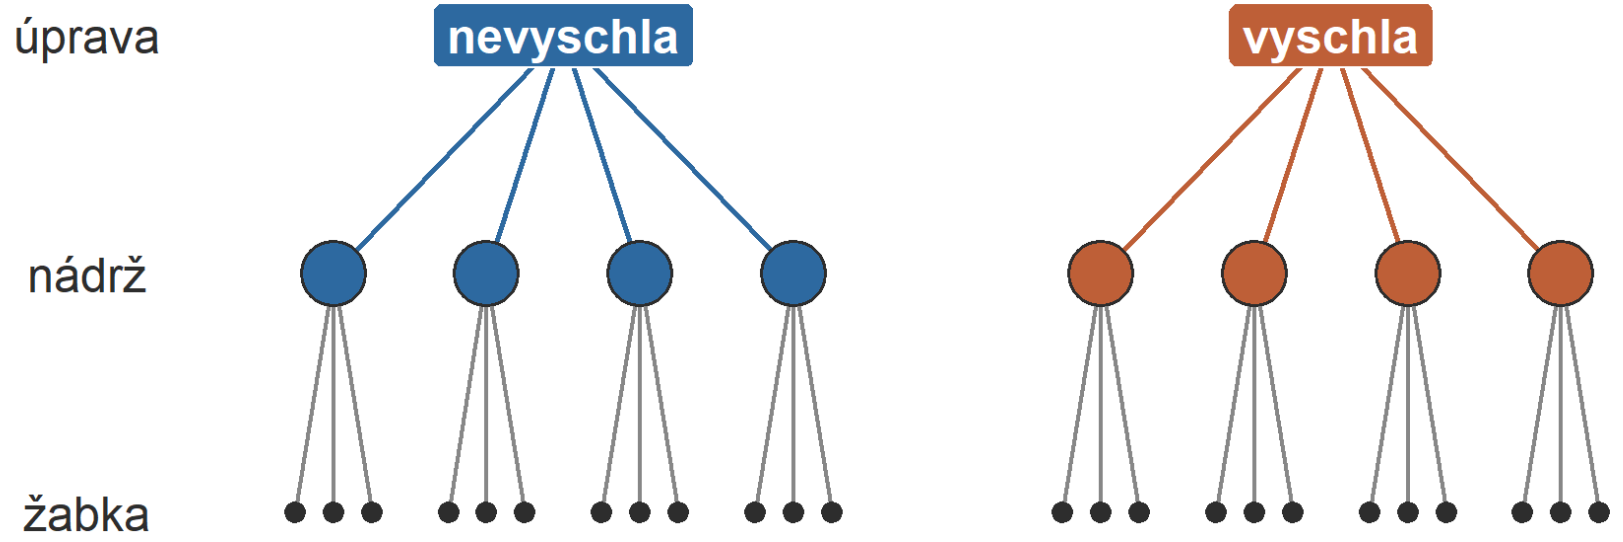


Ve dvojici (po 30 s přemýšlení): Co mají společného žabky z jedné nádrže? Liší se od sebe i nádrže se stejnou úpravou?

Žabky jedné nádrže mají podobné délky. Průměry nádrží se liší i uvnitř úpravy: nevyschlé 26,3–30,6 mm, vyschlé 23,0–26,7 mm.

Kolik nezávislých odpovědí máme?

Žabky v nádržích, nádrže v pokusu



Žabky jsou seskupené v nádržích a úpravu dostaly celé nádrže. Takovým datům říkáme **hierarchická data**.

Stejně vypadá řada biologických dat: **opakovaná měření** jednoho jedince, organismy z jedné **lokality**, plochy v jednom **bloku**. Pozorování ze stejné skupiny si jsou podobnější než pozorování z různých skupin.

Na které úrovni se rozhodovalo o vyschnutí?

Kolik nezávislých odpovědí na otázku „mění vyschnutí tůně velikost žabek?“ dává tento pokus?

A
485 (všechny žabky)

B
295 (žabky z vyschlých nádrží)

C
16 (nádrže)

D
2 (úpravy)

Přesvědčte souseda, proč jste vybrali svoji možnost.

Žabka je jednotka pozorování, nádrž jednotka nezávislé replikace



Ilustrace vytvořená pomocí AI.

JEDNOTKA POZOROVÁNÍ

jeden řádek tabulky: žabka · 485

JEDNOTKA NEZÁVISLÉ REPLIKACE

dostala úpravu nezávisle na ostatních: nádrž · 16

Víc žabek zpřesní nádrž, ale nepřidá další nádrž.

Model, který počítá každou žabku zvlášť

```r
# Každá žabka je samostatným pozorováním
mod_vsechny_zabky <-
  lm(
    formula = delka_tela_mm ~ vyschnuti,
    data = data_zabky
  )

round(
  x = coef(object = summary(object = mod_vsechny_zabky)),
  digits = 3
)
```

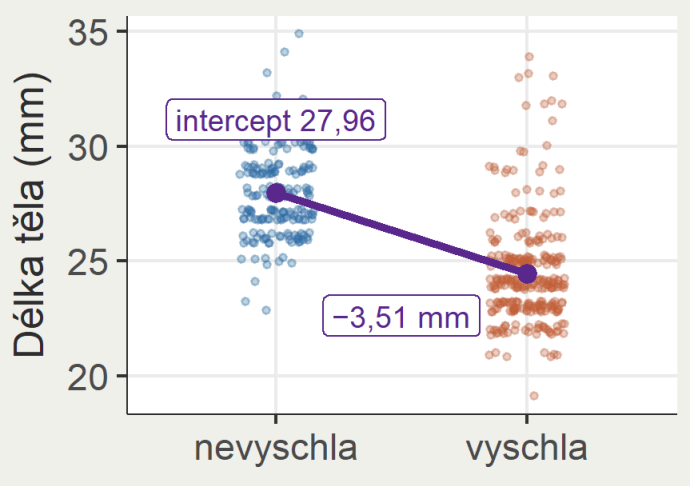
```
                  Estimate Std. Error t value Pr(>|t|)
(Intercept)         27.963      0.155 180.277        0
vyschnutivyschla    -3.506      0.199 -17.626        0
```

```r
confint(object = mod_vsechny_zabky)
```

```
                    2.5 %    97.5 %
(Intercept)      27.65838 28.267936
vyschnutivyschla -3.89632 -3.114741
```

```r
df.residual(object = mod_vsechny_zabky)
```

```
[1] 483
```

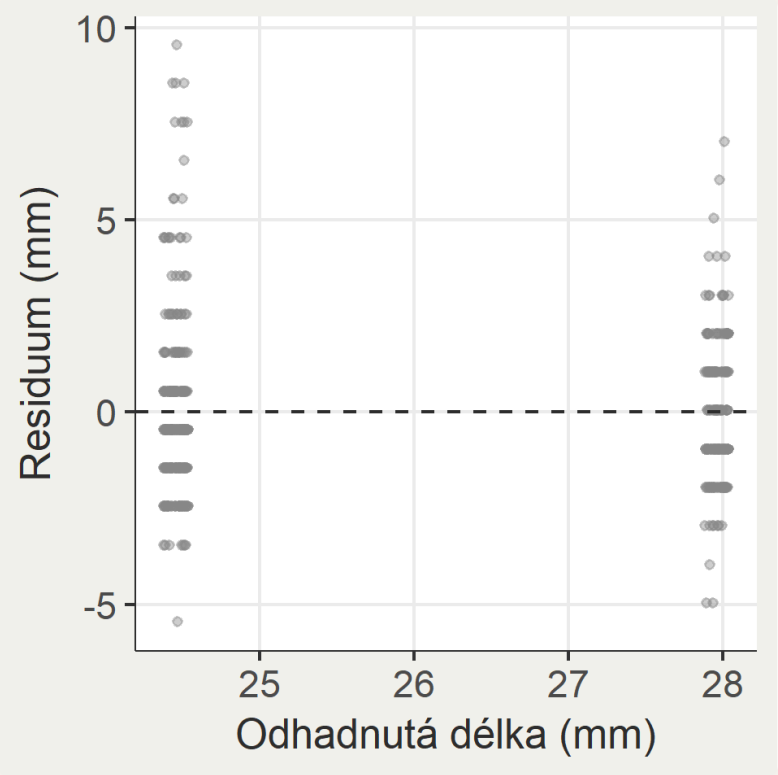


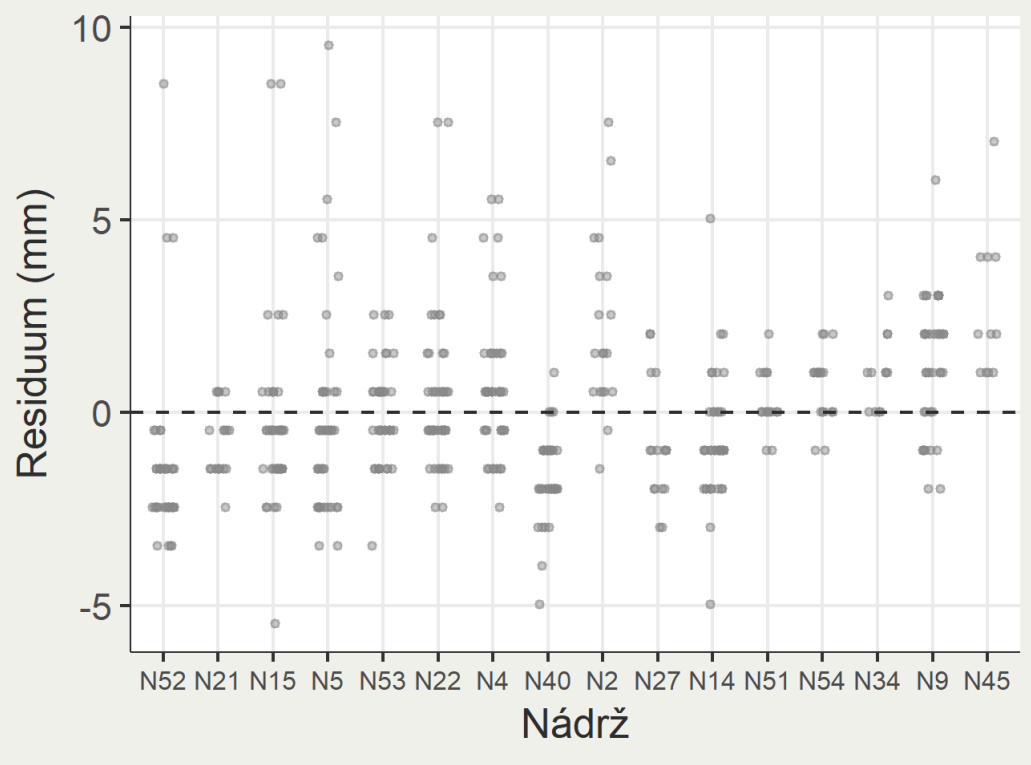
Rozdíl vyschlých nádrží

- odhad **−3,51 mm**;
- SE 0,199 mm;
- 95% CI −3,90 až −3,11 mm;
- 483 stupňů volnosti, $p < 0{,}001$.

Vypadá to **velmi jistě**.

Vypadají residua tohoto modelu v pořádku?





Ve dvojici: Vidíte v tomto grafu něco znepokojivého?

Seřazená podle nádrží: u 6 z 16 nádrží leží průměrné residuum dál než 1 mm od nuly. Residua jedné nádrže se odchylují společně.

Lineární model potřebuje nezávislá pozorování

Co musí platit, aby lineární model odpovídal na otázku (L03)

1. **Tvar vztahu**: u dvou skupin v pořádku.
2. **Rozptýlení kolem odhadu**: v obou skupinách podobné.
3. **Tvar residuí** (normalita, L10): zkontrolujeme u správného modelu.
4. **Nezávislost pozorování**: žabky jedné nádrže si jsou podobné.

Který předpoklad model, který počítá každou žabku zvlášť, porušuje?

Čtvrtý. Z grafu residuí ani z výstupu to nepoznáme, poznáme to z toho, jak data vznikla.

R tento model spočítá, ale jeho SE, interval i p-hodnota neplatí. Pro otázku o vyschnutí je to nesprávný model.

Model, který počítá každou nádrž jednou

```r
# Průměrná délka žabek v každé nádrži
data_nadrze <-
  aggregate(
    x = delka_tela_mm ~ nadrz + vyschnuti,
    data = data_zabky,
    FUN = mean
  )

# Každá nádrž je jedním pozorováním
mod_prumery_nadrzi <-
  lm(
    formula = delka_tela_mm ~ vyschnuti,
    data = data_nadrze
  )

round(
  x = coef(object = summary(object = mod_prumery_nadrzi)),
  digits = 3
)
```

```
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)        28.313      0.437  64.853        0
vyschnutivyschla   -3.763      0.617  -6.095        0
```

```r
df.residual(object = mod_prumery_nadrzi)
```

```
[1] 14
```

Rozdíl vyschlých nádrží

- odhad **−3,76 mm**;
- SE 0,617 mm;
- 14 stupňů volnosti.

Stejně jsme postupovali u **krabů**: jeden řádek = jedno slanisko.

Který model dá širší interval spolehlivosti?

KAŽDÁ ŽABKA ZVLÁŠŤ

`lm(delka_tela_mm ~ vyschnuti)`

485 řádků

KAŽDÁ NÁDRŽ JEDNOU

`lm(delka_tela_mm ~ vyschnuti)`

16 řádků

Pro rozdíl mezi vyschlými a nevyschlými nádržemi dá širší 95% interval spolehlivosti...

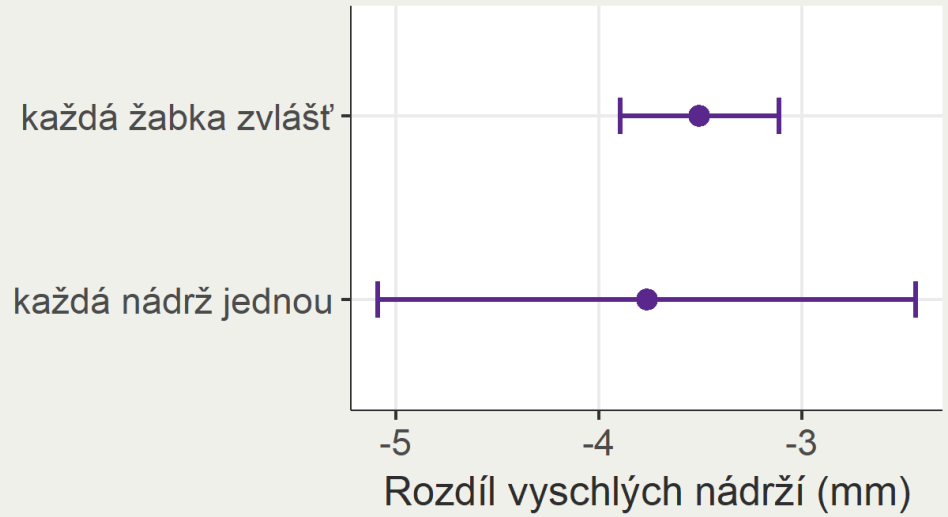
A
model všech žabek

B
model průměrů nádrží

C
oba stejně široký

Stejný rozdíl, mnohem větší nejistota

Model	Rozdíl (mm)	SE (mm)	df
každá žabka zvlášť	−3,51	0,199	483
každá nádrž jednou	−3,76	0,617	14



Odhad se téměř nezměnil. Standardní chyba je ale 3,1krát větší a stupně volnosti klesly z 483 na 14. Rozdíl zůstal jasný, jen víme méně přesně, jak je velký.

Proč 16 nádrží nevydá za 485 žabek



- Žabky jedné nádrže sdílejí vodu i potravu: druhá žabka řekne skoro totéž.
- Model všech žabek proto má příliš malou SE, úzký interval a malou p-hodnotu.
- To je pseudoreplikace: víc falešných poplachů (chyb I. typu).

Ilustrace vytvořená pomocí AI.

Rozhoduje počet skupin, ne počet řádků.

Pokus zopakujete a chcete rozdíl mezi vyschlými a nevyschlými nádržemi odhadnout přesněji. Co pomůže nejvíc?

A
v každé z 16 nádrží změřit dvakrát víc žabek

B
dvakrát víc nádrží, v každé stejně žabek jako dosud

C
měřit žabky přesněji, na desetiny milimetru

D
A i B pomohou stejně, víc měření je víc informace

Přesvědčte souseda, proč jste vybrali svoji možnost.

Víc žabek zpřesní nádrž, víc nádrží zpřesní odpověď



- **A** zpřesní každou nádrž, ne odpověď.
- **B** přidá nezávislé odpovědi.
- **C** rozdíly mezi nádržemi nezmenší.
- **D** neplatí, viz A a B.

Ilustrace vytvořená pomocí AI.

> Víc řádků neznamená víc nezávislých opakování.

Proč jsme u krabů a křídlatky pracovali s průměry

U krabů houslistů jsme modelovali průměry 13 slanisek, ne všech 392 krabů. Proč?

Zeměpisná šířka se mění jen mezi slanisky: 13 nezávislých odpovědí.

SE sklonu: všichni krabi 0,034, průměry slanisek 0,079 mm na stupeň.

Co už o žabkách víme?

Vylézají z tůní, které vyschly, menší žabky?

UŽ UMÍME ŘÍCT

- žabky z vyschlých nádrží jsou kratší asi o 3,8 mm;
- na otázku máme 16 nezávislých odpovědí, ne 485;
- poctivá SE je asi 0,6 mm.

ZATÍM NEVÍME

- Průměry počítají nádrž s 11 i se 47 žabkami stejně a zahodí rozdíly uvnitř nádrží.
- Dá se sestavit model, který zachová každou žabku, a přesto bude počítat nádrže?

Nádrž jako další prediktor?

Co model vypíše pro vyschnutí, když přidáme nádrž?

```r
# Nádrž jako kategoriální prediktor před vyschnutím
mod_nadrz_pevne <-
  lm(
    formula = delka_tela_mm ~ nadrz + vyschnuti,
    data = data_zabky
  )
```

Co model vypíše v řádku pro vyschnutí?

A
podobný rozdíl s menší SE

B
podobný rozdíl s větší SE

C
rozdíl blízký nule

D
žádný odhad

Pro vyschnutí zbylo jen `NA`

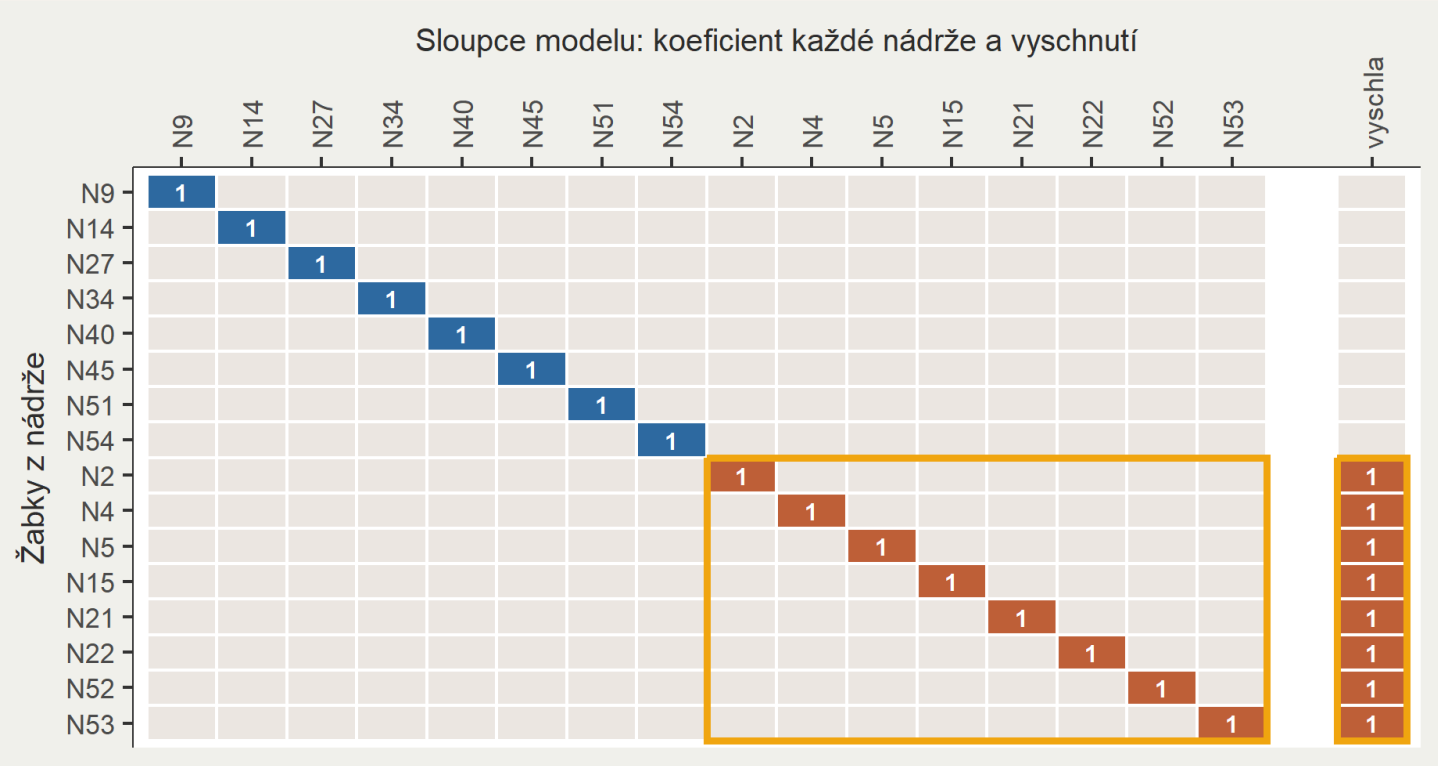
```r
mod_nadrz_pevne <-
  lm(
    formula = delka_tela_mm ~ nadrz + vyschnu
    data = data_zabky
  )

summary(object = mod_nadrz_pevne)
```

```
Coefficients: (1 not defined because of singula
                 Estimate Std. Error t value Pr
...
nadrzN53          -2.2740     0.5316  -4.278 2.
nadrzN54           1.9825     0.6249   3.172 0.
vyschnutivyschla       NA         NA      NA
```

Řádek vyschnutí: `NA`. Jeden koeficient nešel odhadnout (*singularities*).

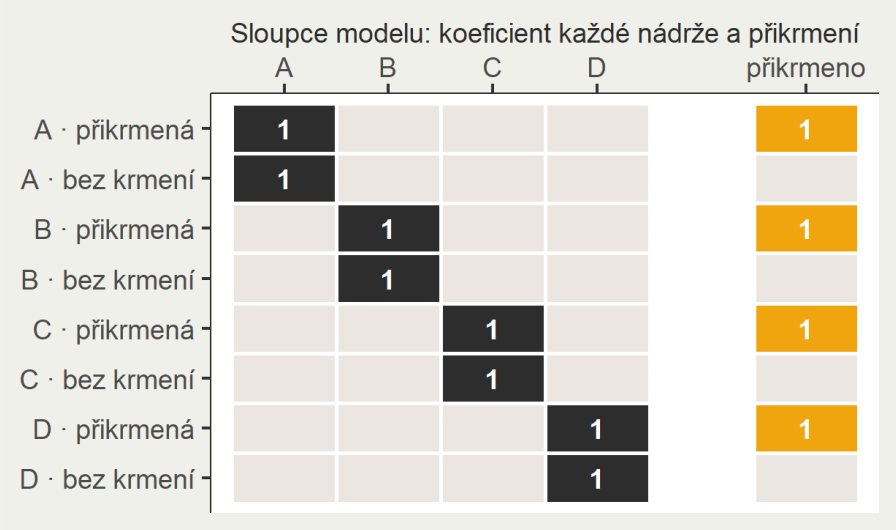
Vyschnutí a nádrž nesou stejnou informaci



Sloupec `vyschla` je součet sloupců vyschlých nádrží: koeficienty nádrží už vyschnutí obsahují. Nádrž je tu pevný faktor.

Prediktor, který se mění jen mezi skupinami, nemůže být v modelu zároveň se skupinou jako pevným faktorem.

Kdy může nádrž zůstat v modelu jako pevný faktor?



Vymyšlený pokus: každá nádrž je přepážkou rozdělená na polovinu, kde pulce přikrmujeme, a polovinu bez krmení.

Úprava se mění uvnitř nádrží. Sloupec `přikrmeno` není součtem sloupců nádrží, a model ho proto odhadne vedle nádrže jako pevného faktoru: porovná poloviny uvnitř každé nádrže.

> Takovou proměnnou v datech žabek máme: den, kdy žabka vylezla z vody, se mění uvnitř každé nádrže.

Souvisí den metamorfózy s délkou žabky?

Žabky vylézaly mezi 41. a 82. dnem: den se mění uvnitř nádrží.

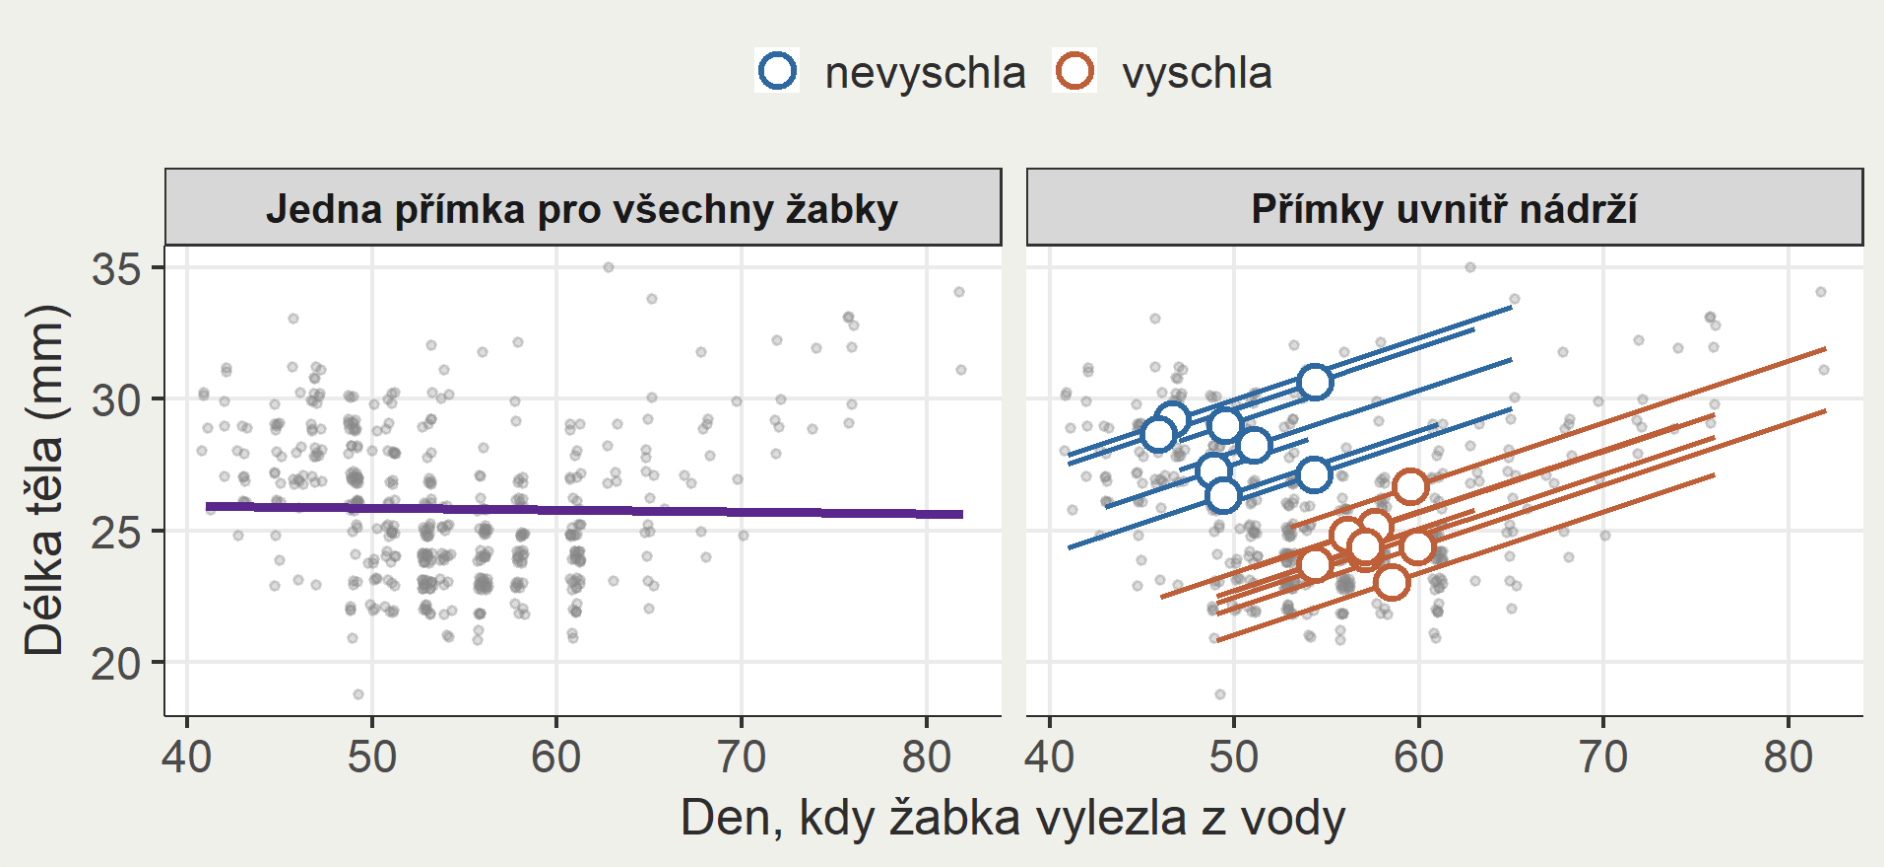
Jaký vztah dne a délky ukáže model, který nádrže nebere v úvahu?

A
rostoucí

B
žádný zřetelný

C
klesající

Uvnitř nádrží jsou pozdější žabky větší



Bez nádrží: sklon −0,007 mm za den (p 0,69). Uvnitř nádrží: **0,23 mm za den** (SE 0,012), za deset dní navíc asi o 2,3 mm.

Proč se vztah ukázal až uvnitř nádrží

Vyschlé nádrže: žabky později (58. vs. 49. den) a menší. Rozdíly **mezi nádržemi** překryly vztah **uvnitř nádrží**.

PREDIKTOR SE MĚNÍ JEN MEZI SKUPINAMI

vyschnutí → nádrž jako pevný faktor nepomůže

PREDIKTOR SE MĚNÍ UVNITŘ SKUPIN

den metamorfózy → pevný faktor pomůže: porovnává žabky ze stejné nádrže

Stejně fungují bloky v terénních pokusech a opakovaná měření jednoho jedince.

Každá nádrž má vlastní výchozí úroveň

Zajímá nás konkrétní nádrž, nebo nádrže obecně?



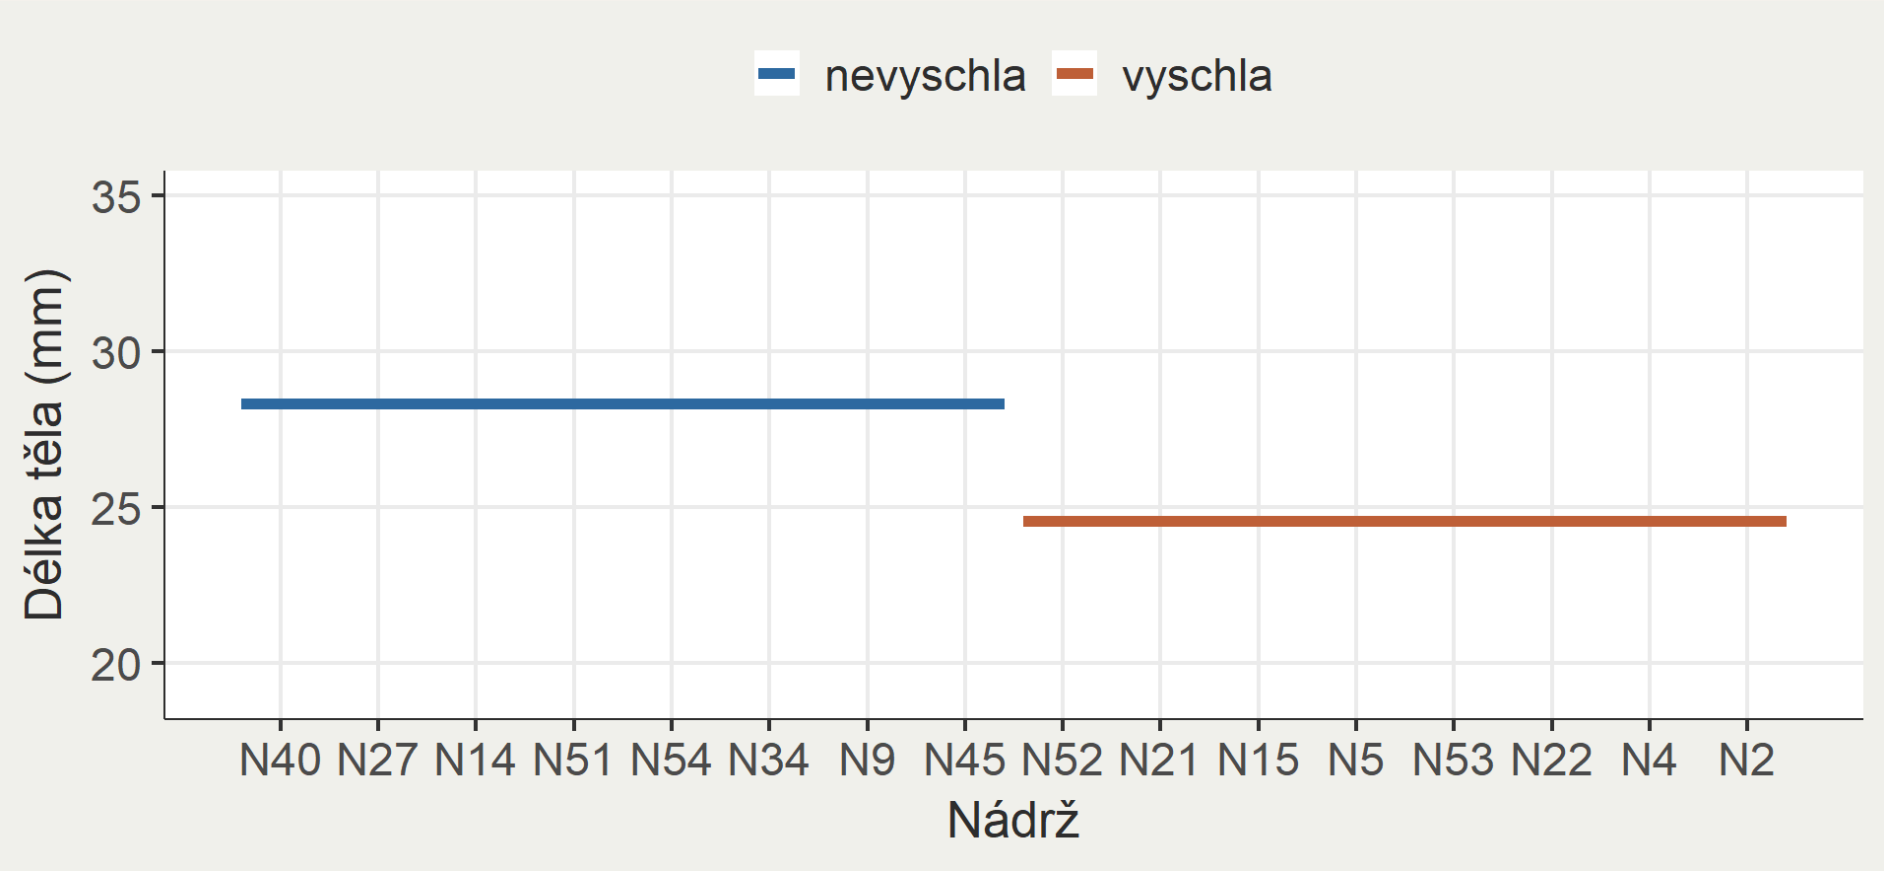
Ilustrace vytvořená pomocí AI.

Při opakování pokusu bychom vzali jiné nádrže. Vyschnutí by ale mělo stejné dvě úrovně.

> Chceme vědět něco o nádržích N27 a N54, nebo o tůních obecně?

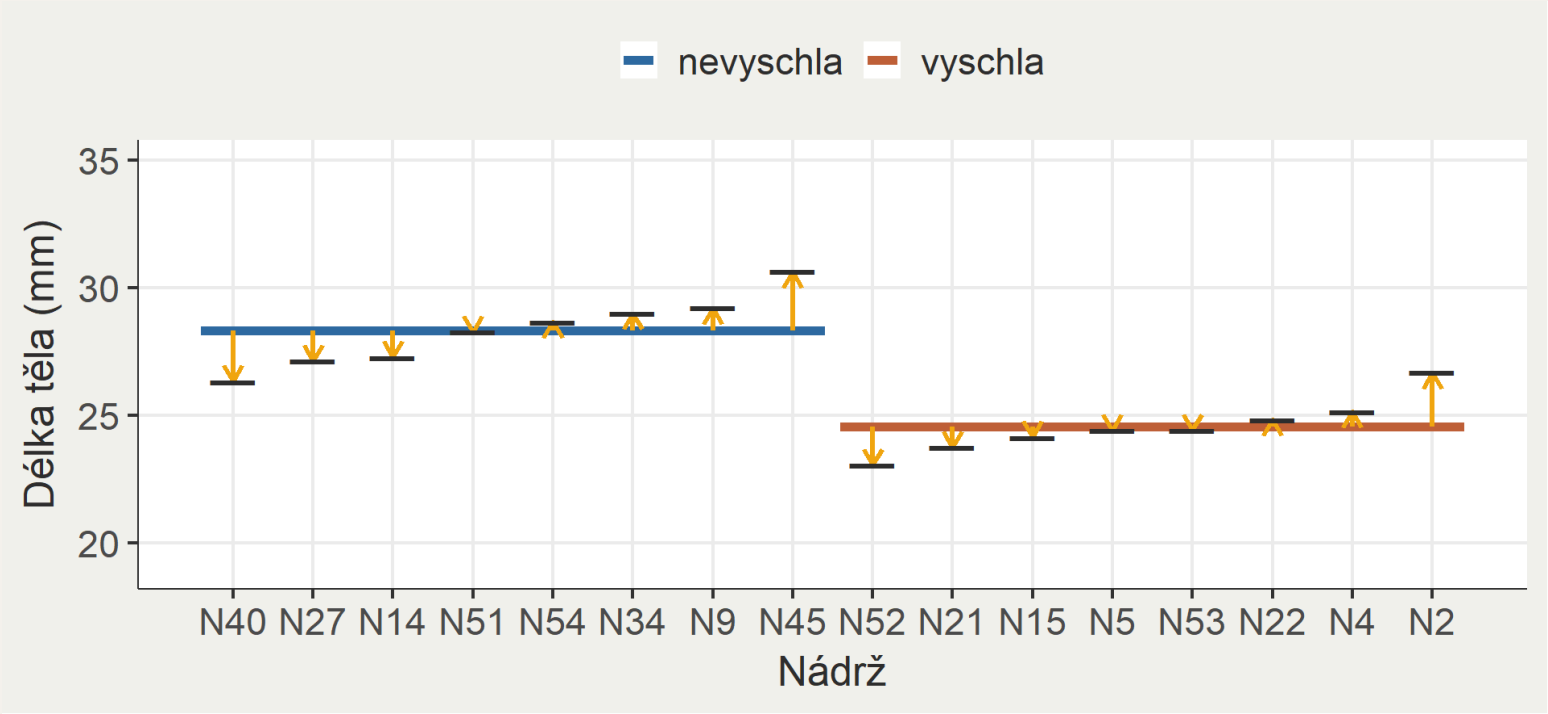
O tůních obecně. Nádrže jsou vzorek z mnoha možných tůní; zajímá nás, jak moc se tůně obvykle liší.

Z čeho se skládají délky žabek?



Kdyby každá žabka měřila přesně průměr své úpravy, data by vypadala takto. Co v nich chybí?

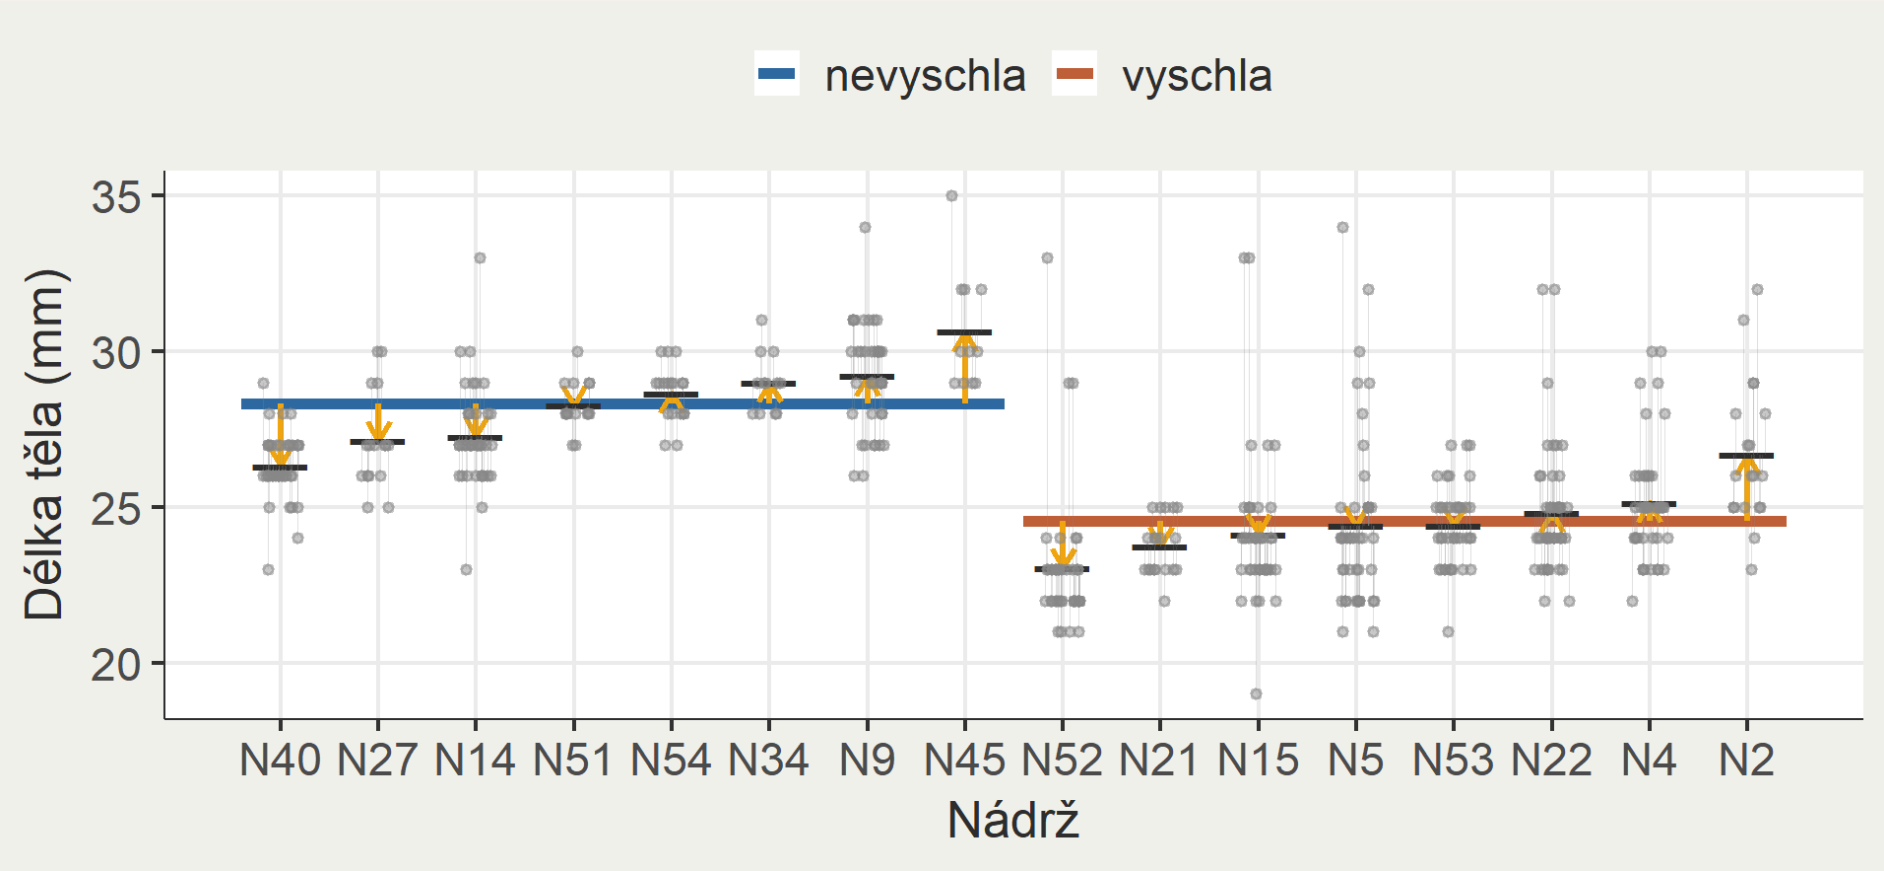
Z čeho se skládají délky žabek?



\+ posun nádrže: každá nádrž leží o kus výš, nebo níž, na obě strany a jen málokdy hodně.

Posuny si můžeme představit jako náhodné tahy z rozdělení podobného normálnímu. Skupinové proměnné, jejíž úrovně chápeme jako výběr z mnoha možných, říkáme náhodný faktor; posuny jednotlivých skupin jsou náhodné efekty.

Z čeho se skládají délky žabek?



délka žabky = průměr úpravy + posun nádrže + odchylka žabky (šedé čáry). Obyčejné `lm()` slučuje poslední dvě části do jednoho residua; nový model je drží odděleně.

Z čeho se skládá délka jedné žabky

$$\begin{aligned}\text{odhadnutá délka žabky} &= \text{intercept} \\ &+ \text{rozdíl po vyschnutí} \times \text{přepínač ‚vyschla?‘} \\ &+ \text{odchylka nádrže}\end{aligned}$$

Žabka z nádrže N21, naměřeno 23 mm: intercept 28,27 mm, rozdíl po vyschnutí −3,73 mm, přepínač ‚vyschla?‘ = 1, odchylka nádrže −0,70 mm.

$$28{,}27 + (-3{,}73) \times 1 + (-0{,}70) = 23{,}84\ \text{mm}$$

Residuum: $23 - 23{,}84 = -0{,}84$ mm, odchylka této žabky od výchozí úrovně její nádrže.

Z čeho se skládá délka jedné žabky

$$y_{ij} = \beta_0 + \beta_1 x_j + u_j + e_{ij}$$

- y_{ij} délka žabky i z nádrže j; β_0 intercept; β_1 rozdíl po vyschnutí; x_j přepínač ‚vyschla?' (1, pokud nádrž vyschla);
- u_j posun nádrže j: pochází z normálního rozdělení s průměrem 0 a neznámou směrodatnou odchylkou;
- e_{ij} residuum žabky.

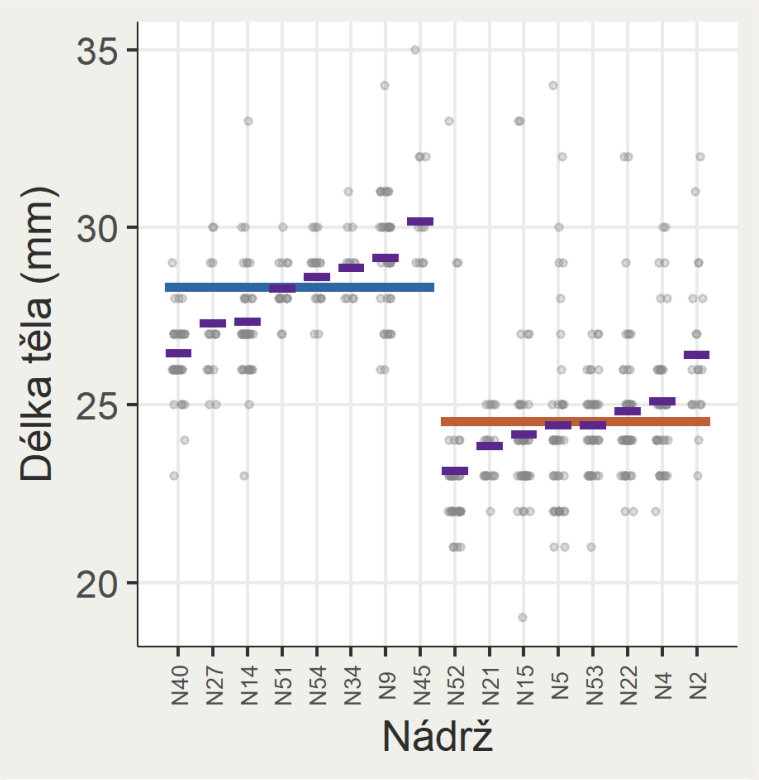
> Posun u_j mění intercept každé nádrže: je to **náhodný intercept**. Model s pevnými i náhodnými efekty je **smíšený model**.

Model s náhodným interceptem v R

```r
# Vyschnutí je pevný efekt, nádrž náhodný intercept
mod_smiseny <-
  glmmTMB::glmmTMB(
    formula = delka_tela_mm ~ vyschnuti + (1 | nadrz),
    data = data_zabky,
    REML = TRUE
  )
```

`(1 | nadrz)`
„Intercept (`1`) se liší podle (`|`) nádrže.“ Zbytek vzorce je stejný jako u `lm()` .

Proč `glmmTMB()`
`lm()` náhodné efekty odhadnout neumí. `glmmTMB()` má stejný zápis vzorce a je dostatečně flexibilní i pro složitější modely.



Přerušovaná v barvě úpravy: průměrná nádrž úpravy · fialová: výchozí úroveň nádrže

Bude standardní chyba blíž modelu žabek, nebo modelu nádrží?

KAŽDÁ ŽABKA ZVLÁŠŤ
SE 0,199 mm

KAŽDÁ NÁDRŽ JEDNOU
SE 0,617 mm

Smíšený model pracuje se všemi 485 žabkami. Jakou SE dá pro rozdíl vyschlých nádrží?

A
kolem 0,2 mm

B
mezi oběma

C
kolem 0,6 mm

D
víc než 0,6 mm

Jak velký je rozdíl a jak přesně ho známe

```
summary(object = mod_smiseny)
```

```
Conditional model:
                  Estimate Std. Error z value Pr(>
(Intercept)        28.2667     0.4336   65.19  < 2
vyschnutivyschla  -3.7280     0.6044   -6.17 6.93
```

```
confint(
  object = mod_smiseny,
  parm = "beta_"
)
```

```
                       2.5 %    97.5 % Estimate
(Intercept)       27.416857 29.116476 28.26667
vyschnutivyschla -4.912673 -2.543287 -3.72798
```

Rozdíl **−3,73 mm**, SE **0,604 mm**, 95% CI −4,91 až −2,54 mm.
SE ≈ model průměrů nádrží (0,617 mm): model **počítá nádrže, ne žabky**.

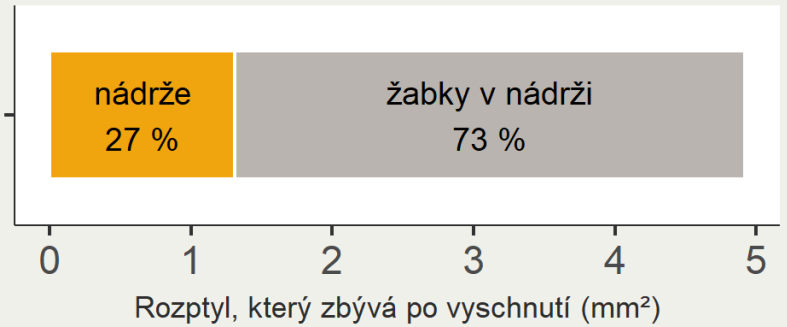
Liší se víc nádrže, nebo žabky v jedné nádrži?

```
Random effects:

Conditional model:
 Groups   Name        Variance Std.Dev.
 nadrz    (Intercept) 1.310    1.145
 Residual             3.612    1.901
Number of obs: 485, groups:  nadrz, 16
```

Liší se víc nádrže mezi sebou, nebo žabky uvnitř jedné nádrže?

- nádrže: 1,14 mm
- žabky v nádrži: 1,90 mm



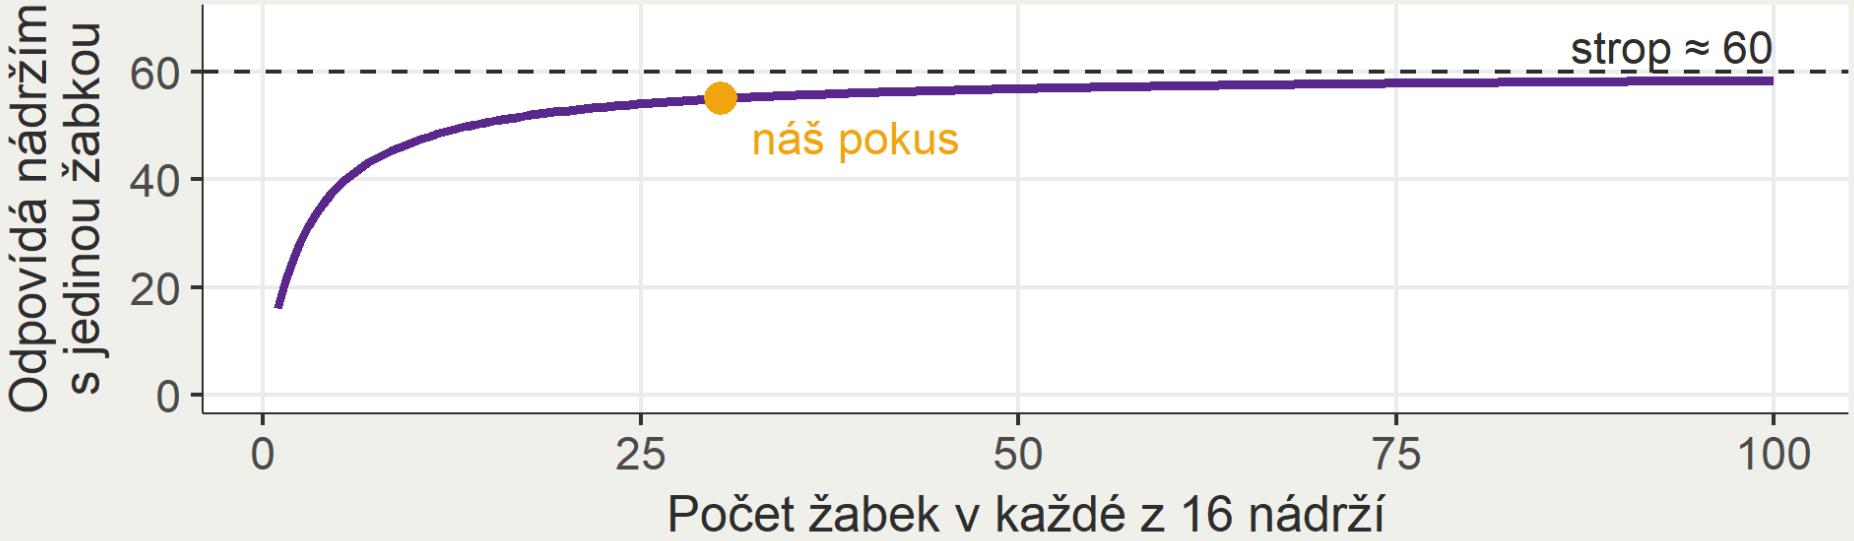
Rozptyl je druhá mocnina SD. Asi 27 % zbylé variability připadá na nádrže.

Kolik nezávislé informace je v 16 nádržích?

Návrh A · mnoho malých nádrží, v každé jediná žabka: každá žabka je nezávislá.

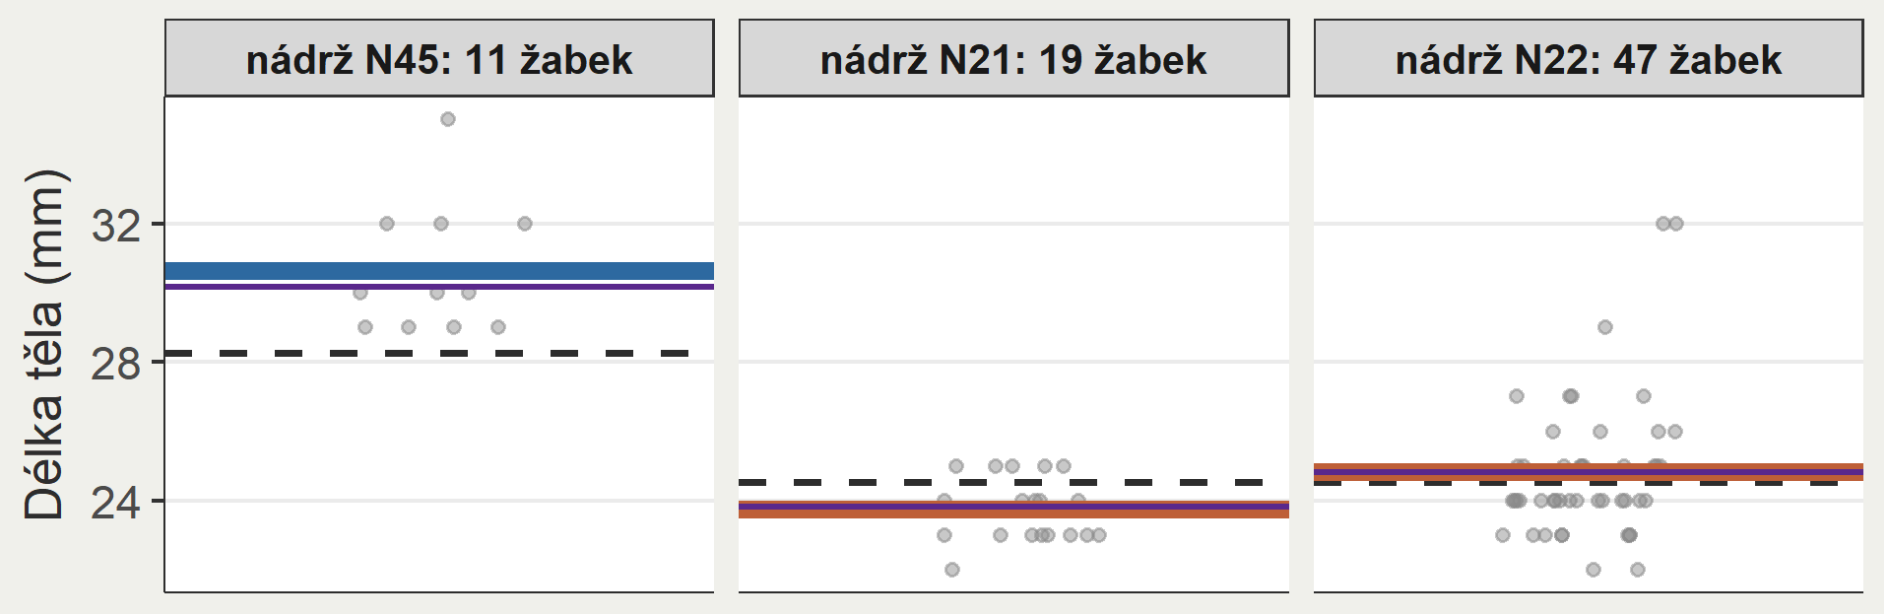
Návrh B · náš pokus: 16 nádrží, v každé průměrně 30 žabek.

Kolik malých nádrží s jedinou žabkou by dalo stejně přesný odhad jako náš pokus?



Asi 55 nádrží s jedinou žabkou, ne 485. Ani s nekonečně mnoha žabkami v nádrži by to nebylo víc než asi 60. Proto je SE smíšeného modelu asi 3,0krát větší než u modelu všech žabek.

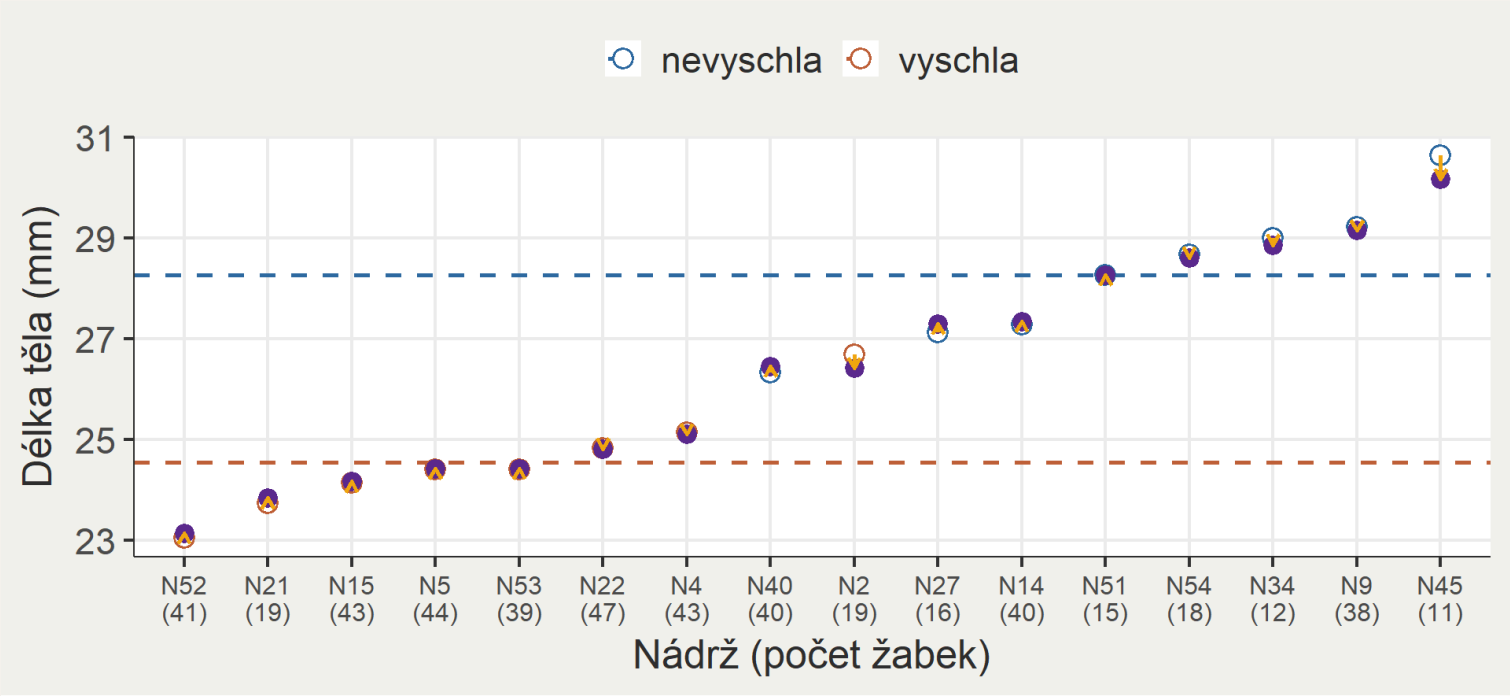
Malá, střední a velká nádrž: čemu model věří?



Přerušovaná čára: průměr úpravy · plná barevná: průměr žabek z nádrže · fialová: odhad modelu

Ve dvojici: Kam model umístí výchozí úroveň malé a kam velké nádrže? Na průměr nádrže, na průměr úpravy, nebo mezi ně?

Kde leží odhadnuté výchozí úrovně nádrží?

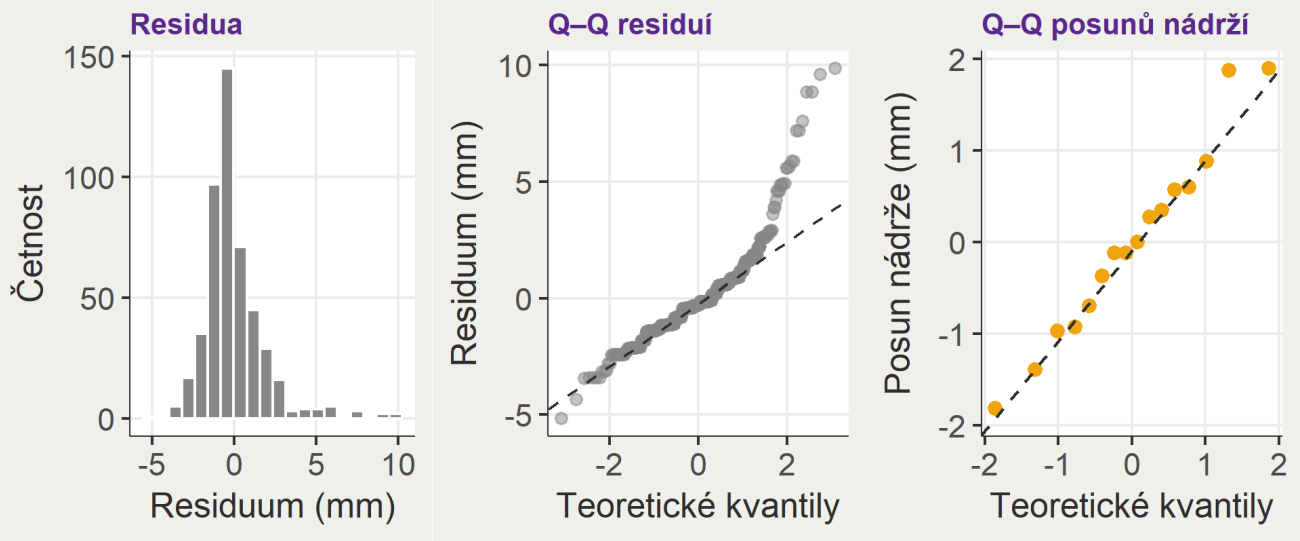


Prázdný kruh: průměr žabek z nádrže · fialový bod: odhad modelu · oranžová šipka: posun mezi nimi · přerušovaná čára: průměr úpravy

Ve dvojici: Které nádrže se posunuly nejvíc a proč?

Nejvíc nádrž N45 (11 žabek): 0,47 mm. Nádrže se 40 a více žabkami nanejvýš 0,13 mm. Malá nádrž si „půjčí“ část informace od ostatních.

Co prozradí residua a výchozí úrovně nádrží?



Smíšený model už počítá s tím, že žabky jedné nádrže nejsou nezávislé. **Ve dvojici:** Který předpoklad zbývá zkontrolovat? Platí?

Tvar residuí (L10). Neplatí: residua mají dlouhý pravý chvost (šikmost 1,8). Posuny nádrží leží přibližně na přímce, ale je jich jen 16.

Chvost tvoří několik pozdě vylezlých, velkých žabek. Závěr o vyschnutí přesto platí: model průměrů nádrží, který na tvaru residuí jednotlivých žabek nestojí, dal skoro stejný rozdíl (−3,76 oproti −3,73 mm).

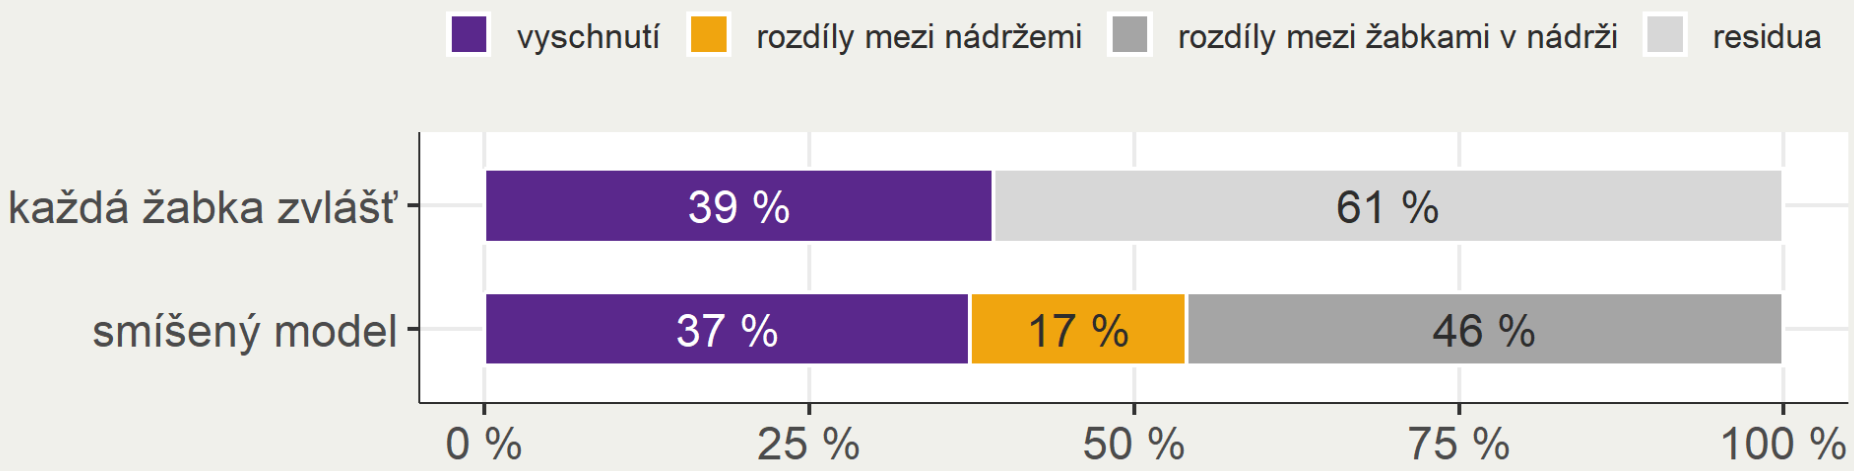
Kolik variability zachytí vyschnutí a kolik nádrže?

Na kterou část připadne největší díl variability v délce žabek?

A
rozdíl mezi vyschlými a nevyschlými

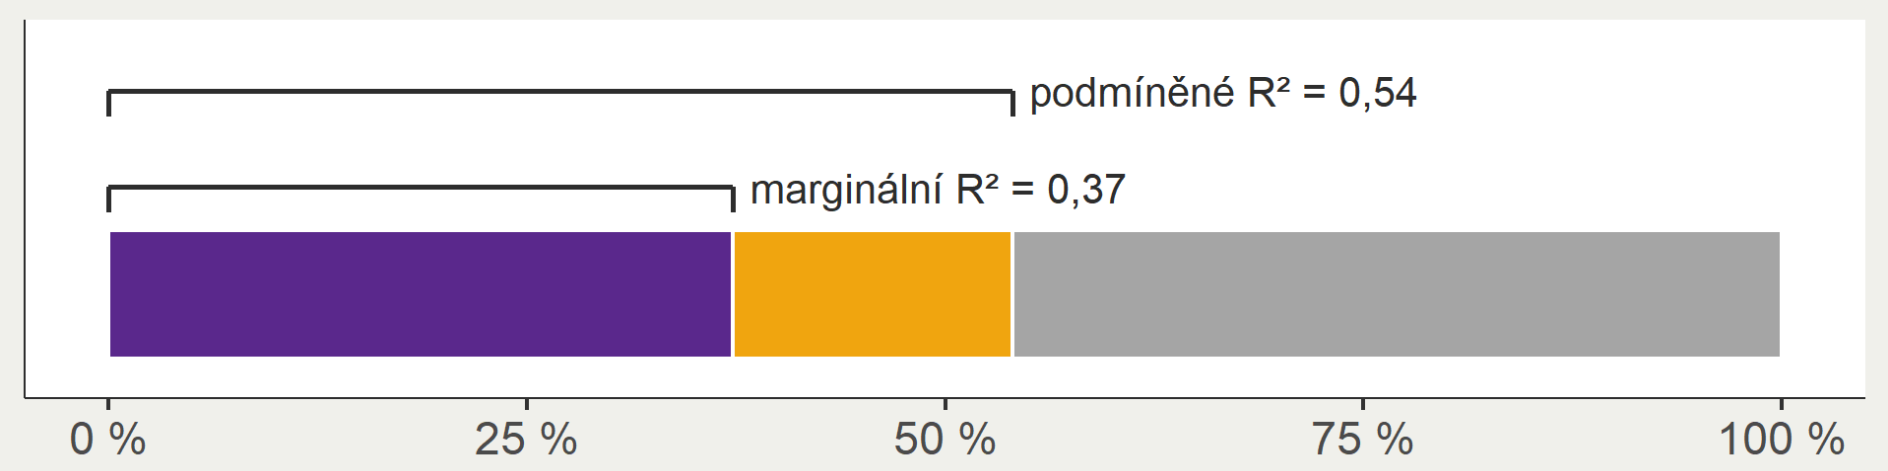
B
rozdíly mezi nádržemi se stejnou úpravou

C
rozdíly mezi žabkami v jedné nádrži



Vyschnutí zůstalo **téměř stejné**; residua se rozdělila na **nádrže** a žabky.

Marginální a podmíněné R^2



MARGINÁLNÍ R^2

fialová část: jen pevné efekty (vyschnutí), tedy kolik zachytí prediktor, který nás zajímá

PODMÍNĚNÉ R^2

fialová + oranžová část: pevné i náhodné efekty, tedy kolik zachytí celý model, když zná nádrže

Vysoké podmíněné R^2 neznamená důležité vyschnutí: rozdíly mezi nádržemi model popisuje, ale nevysvětluje.

Čtyři způsoby, jak odpovědět na stejnou otázku

Postup	Nezávislé jednotky	Rozdíl (mm)	SE (mm)
každá žabka zvlášť	485 žabek	−3,51	0,199
průměry nádrží	16 nádrží	−3,76	0,617
nádrž jako pevný faktor	—	nelze	—
náhodný intercept	16 nádrží	−3,73	0,604

Kdy stačí jednodušší řešení? Když se prediktor mění jen mezi skupinami, skupiny mají podobný počet pozorování a žádný prediktor se nemění uvnitř skupin, dají průměry skupin prakticky stejnou odpověď jako smíšený model.

Pevný, nebo náhodný faktor?

Zajímají nás konkrétní úrovně, nebo celý soubor možných úrovní?

1. Zajímají nás konkrétní úrovně?
2. Opakovaly by se v novém pokusu?
3. Je jich dost (zhruba pět a víc)?
4. Mění se prediktor jen mezi skupinami?



Ilustrace vytvořená pomocí AI.

U žabek: vyschnutí pevný, nádrž náhodný faktor (16 nádrží).

Pevný, nebo náhodný? Šest situací z biologie

1 · Pokus v květináčích porovnává růst tří konkrétních druhů trav.
druh: pevný

2 · Na 20 lokalitách podél řeky měříte pstruhy a zajímá vás teplota vody.
lokalita: náhodný

3 · Na poli je 8 bloků a v každém jsou všechny čtyři dávky hnojiva.
blok: náhodný

4 · Každého z 30 netopýrů zvážíte v pěti různých měsících.
netopýr: náhodný

5 · Porovnáváte délku křídla samců a samic.
pohlaví: pevný

6 · Velikost ryb měříte jen ve třech jezerech.
jezero: opatrně, spíš pevný

Ve skupinkách po 3–4, 2 minuty: pevný, nebo náhodný faktor, a proč?

Když nepomůže ani model: jedno ošetřené povodí



Hubbard Brook: vápník na celé jedno povodí, vedle jedno kontrolní. Změřeny stovky semenáčků javoru.

> Kolik nezávislých odpovědí o vápníku máme?

Jednu ošetřenou a jednu kontrolní.

Ilustrace vytvořená pomocí AI.

Model nezávislé jednotky nevytvoří. Chybě v návrhu je potřeba předejít.

Závěr

Napište závěr o žabkách dvěma větami

Co víme

- smíšený model: rozdíl **−3,73 mm**, 95% CI −4,91 až −2,54 mm;
- jednotka nezávislé replikace: nádrž, **16 nádrží**;
- vyschnutí zachytí asi 37 % variability v délce žabek.

Zapište si sami (40 s) a porovnejte se sousedem:
„Žabky z vyschlých nádrží byly … (95% interval …); odpověď stojí na … nezávislých nádržích.“
„Hlavním omezením je …“

Vylézají z vyschlých nádrží menší žabky?



Ano: v průměru o **3,7 mm kratší** (95% CI 2,5 až 4,9 mm), odpověď z 16 nezávislých nádrží.

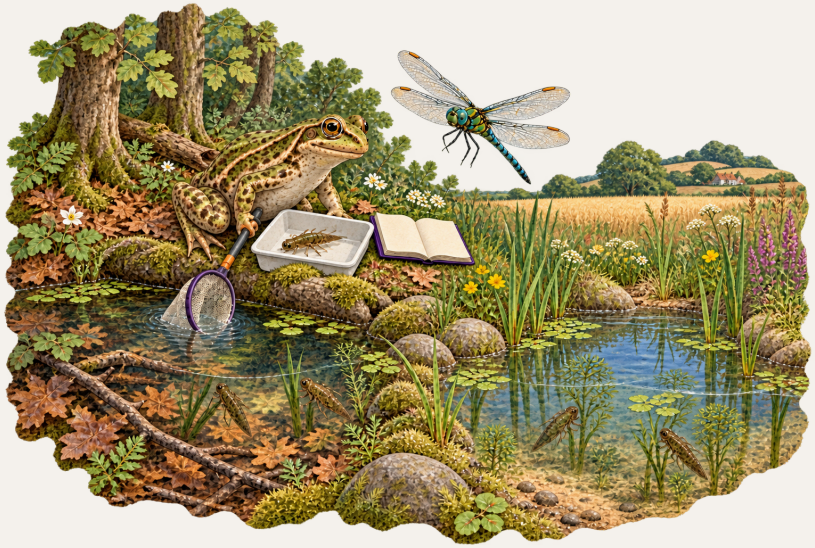
OMEZENÍ

- víc přeživších pulců ve vyschlých nádržích (295 vs. 190 žabek);
- jen 16 nádrží;
- nádrže nejsou divoké tůně.

Ilustrace vytvořená pomocí AI.

Paralelní studie: larvy vážek v lesních a polních tůních

Krok 1: Jakou otázku si položíme a co budeme měřit?



Ilustrace vytvořená pomocí AI.

Jsou larvy vážek v tůních obklopených lesem jinak velké než v tůních mezi poli?

> **Ve dvojici:** Co budeme měřit a s jakou jednotkou? Co porovnáme? Kde a jak budeme sbírat?

Délku těla larvy v mm. Porovnáme okolí tůně: les, nebo pole. V několika oblastech vybereme lesní a polní tůně a v každé odchytíme síťkou několik larev.

Vymyšlený příklad pro plánování, data k němu nemáme.

Krok 2: Kolik nezávislých odpovědí dá který návrh?

Stejných 240 larev lze nasbírat dvěma způsoby:

Návrh 1 · 24 tůní po 10 larvách

Návrh 2 · 4 tůně po 60 larvách

Ve dvojici: Na které úrovni se mění okolí? Kolik nezávislých odpovědí dá každý návrh na otázku „les, nebo pole?“



Ilustrace vytvořená pomocí AI.

Okolí se mění mezi tůněmi, ne mezi larvami; jednotkou nezávislé replikace je tůň. Návrh 1: 24 odpovědí. Návrh 2: jen 4, tedy 2 lesní a 2 polní tůně.

Krok 3: Co se mění uvnitř tůní a dá se to využít?

Ve dvojici: Co se u larev mění uvnitř jedné tůně? Dají se tůně seskupit do bloků s podobnými podmínkami?

Uvnitř tůně se mění velikost a stadium larev a datum odběru, podobně jako den metamorfózy u žabek. Když lesní a polní tůně vybíráme ve stejných 6 oblastech, po 2 lesních a 2 polních, je oblast blok: les a pole porovnáváme v podobném podnebí.



Ilustrace vytvořená pomocí AI.

Krok 4: Které faktory budou pevné a které náhodné?

Ve dvojici: Je okolí, tůň a oblast pevný, nebo náhodný faktor? Má každá úroveň okolí několik nezávislých tůní?

Okolí (les, pole) je pevný faktor; tůň a oblast jsou náhodné faktory. Lesních i polních tůní musí být několik v každé oblasti: jedna lesní a jedna polní tůň by byly stejná past jako jedno pohnojené povodí.



Ilustrace vytvořená pomocí AI.

Krok 5: Jak zapíšeme model?

> **Ve dvojici:** Co bude jeden řádek tabulky? Napište vzorec ve tvaru `odezva ~ prediktor + (1 | jednotka)`.

Jeden řádek = jedna larva.

`delka_larvy_mm ~ okoli + (1 | tun)`, kde `okoli` má úrovně `les` a `pole`.



Ilustrace vytvořená pomocí AI.

Sedm otázek před prvním měřením

1. Jaká je otázka a co budu měřit (s jednotkou)? krok 1
2. Na které úrovni se mění prediktor, který mě zajímá? krok 2
3. Co je jednotka nezávislé replikace? krok 2
4. Kolik jednotek a kolik měření v každé? krok 2
5. Co se mění uvnitř jednotek a dá se využít (bloky, dvojice, opakovaná měření)? krok 3
6. Které skupinové proměnné budou pevné a které náhodné? krok 4
7. Jak bude vypadat model? Vzorec zapište dřív, než začnete sbírat data. krok 5



Ilustrace vytvořená pomocí AI.

K návrhu patří i kontrola, která se od ošetření liší jen zkoumanou úpravou, a náhodné přidělení úprav, třeba losem. Pro vlastní studii projděte stejných pět kroků; šablona návrhu na jednu stránku je ve skriptech.

Shrnutí lekce

Co si odnést

- Počet řádků ≠ počet nezávislých opakování: rozhoduje úroveň prediktoru.
- Pseudoreplikace podhodnotí nejistotu.
- Průměry skupin jsou poctivé, ale ztrácejí informaci.
- Náhodný intercept: vlastní výchozí úroveň pro každou skupinu, nejistota podle počtu skupin.
- Chybějící jednotky žádný model nenahradí: o návrhu se rozhoduje před měřením.

Co když nás nezajímá délka, ale přežití pulců?

U každého z 50 pulců v nádrži zapíšeme, zda přežil do metamorfózy: ano, nebo ne.

> **Ve dvojici:** Co je jeden řádek tabulky, když sledujeme přežití? Co je jednotka nezávislé replikace? Patří do modelu stále `(1 | nadrz)`?

Řádek je pulec, jednotkou replikace zůstává nádrž a `(1 | nadrz)` do modelu patří dál: hierarchie dat vzniká tím, jak data sbíráme, ne tím, co měříme. Změní se jen typ odezvy, a ten přinese příští lekce.